Міністерство освіти і науки України
Національний технічний університет України
«Київський політехнічний інститут імені Ігоря Сікорського»
Інститут прикладного системного аналізу
Кафедра математичних методів системного аналізу

ЗВІТ

про виконання лабораторної роботи № 4
з дисципліни «Інтелектуальний аналіз даних»

Виконала:
Студентка III курсу
Групи КА-76
Оркуша А. Д.

Перевірила:
Недашківська Н. І.

Київ – 2020

Варіант 11

StackingClassifier. Розглянути різні значення параметрів final_estimator та stack_method.

StackingClassifier - ансамбль моделей класифікації. Моделі, що вказуються у параметрі estimators тренуються незалежно на тренувальних даних, потім зроблені ними передбачення надаються на вхід моделі, що вказується у параметрі final_estimator. Її тренування в свою чергу відбувається за допомогою перехресного пошуку. Таким чином враховується “вклад” кожної з моделей.

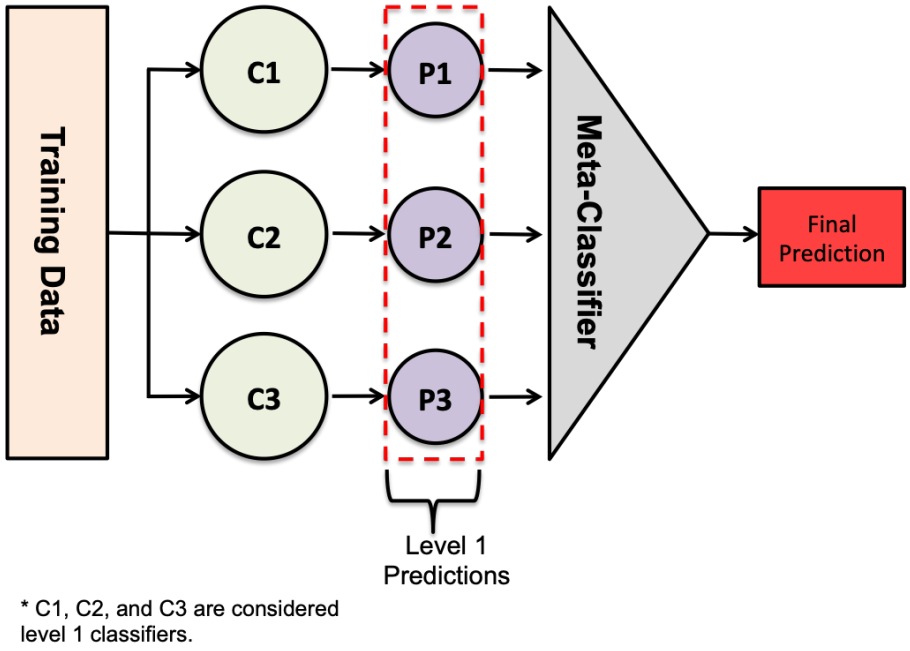

Дослідити ансамблі, які включають моделі нейронних мереж та моделі наївної байесівської класифікації, отримані в роботі №2.

В моделях нейронних мереж:

• побудувати різні архітектури мереж шляхом варіювання значень параметру hidden_layer_sizes; порівняти результати класифікації, отримані на основі різних архітектур

• розглянути різні значення max_iter, дослідити їх вплив на результат

Хід виконання роботи

1. Взяти дані з роботи № 2 згідно з варіантом. Представити дані графічно.

(a)load_digits

Цей датасет складається з набору n_samples зображень рукописних цифр (розміром 8x8), що представлені(закодовані) у вигляді цілочисельних векторів (1x64), та вектору розмірністю 1x n_samples - вектору класів до якого належить кожен з прикладів. Для графічного представлення покажемо декілька зображень цих цифр з підписом класу до якого вони належать у лівому верхньому куті.

In [1]:

```
from sklearn import datasets, inspection, metrics
import matplotlib.pyplot as plt

digits_X, digits_y = datasets.load_digits(return_X_y=True)


fig = plt.figure()
fig.subplots_adjust()

for i in range(9):
   ax = fig.add_subplot(3, 3, i + 1, xticks=[], yticks=[])
   ax.imshow(digits_X[i].reshape((8,8)), cmap=plt.cm.gray_r, interpolation='nearest')
   ax.text(0.1, 0.7, str(digits_y[i]))
plt.show()
```

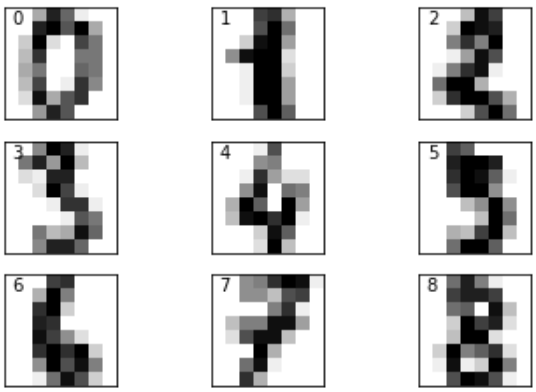

Окрім цього корисно візуалізувати належність усіх прикладів конкретним класам. Оскільки дані багатовимірні, використаємо метод головних компонент(PCA) для зменшення вимірності.

In [2]:

```
from sklearn.decomposition import PCA
import scikitplot as skplt

pca = PCA(n_components=2)
pca.fit(digits_X)
skplt.decomposition.plot_pca_2d_projection(pca, digits_X, digits_y, title='Digits 2-D
Projection')
```

Out[2]:

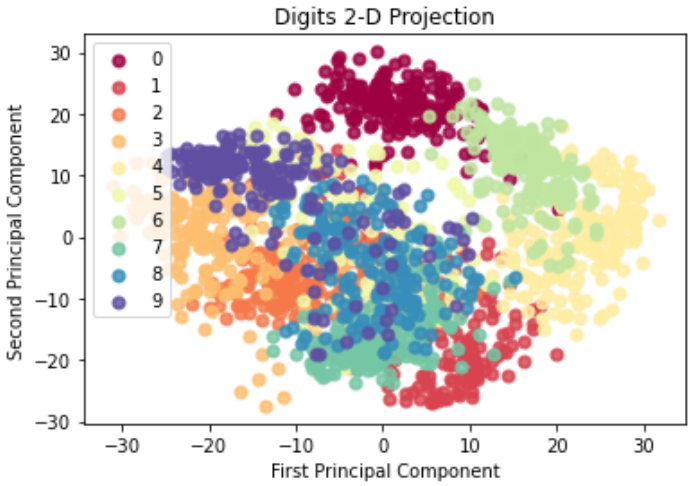

(b)make_moons

Цей датасет складається з набору n_samples двовимірних точок, що утворюють два півкола котрі напів перетинаються, та вектору з 0 та 1 що описує якому півколу(класу) належить точка. Параметр noise описує ступінь розкиданості прикладів в датасеті відносно ліній півкіл.

In [3]:

```
from pandas import DataFrame

moons_X, moons_y = datasets.make_moons(n_samples=1200, noise=0.3)

df = DataFrame(dict(x=moons_X[:, 0], y=moons_X[:, 1], label=moons_y))
colors = {0: 'orange', 1: 'purple'}
fig, ax = plt.subplots()
```

```
grouped = df.groupby('label')
for key, group in grouped:
   group.plot(ax=ax, kind='scatter', x='x', y='y', label=key, color=colors[key])
plt.show()
```

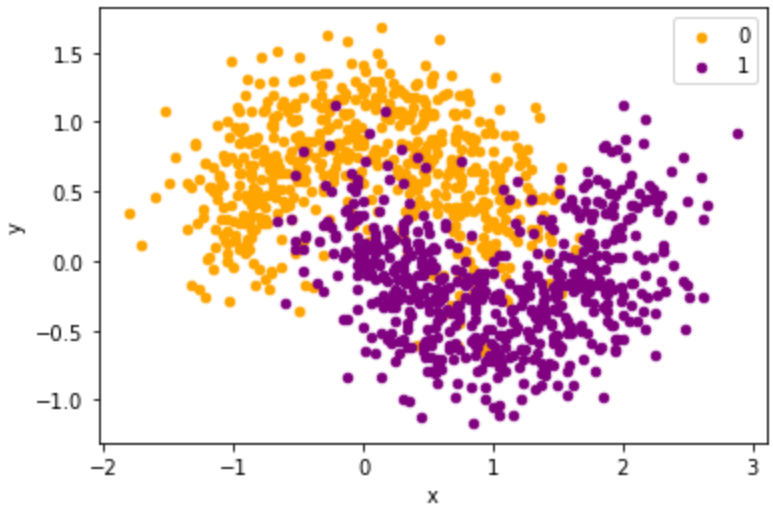

2. Побудувати моделі нейронних мереж, використовуючи клас MLPClassifier. Дослідити вплив різних параметрів MLPClassifier на результат класифікації:

Для початку врахуємо що багатошаровий персептрон чутливий до масштабування вхідних даних. Дані можуть бути приведені до діапазону [0, 1] або [−1, +1], або приведені до нульового середнього та одиничної дисперсії. Проведемо масштабування даних. Для digits обираємо `MinMaxScaler` щоб дані залишилися додатніми, щоб було можливим застосування MultinomialNB у подальшому.

In [4]:

```
from sklearn.preprocessing import MinMaxScaler
from sklearn.preprocessing import StandardScaler

moons_X = StandardScaler().fit_transform(moons_X)
digits_X = MinMaxScaler().fit_transform(digits_X)
```

Розібємо дані на тренувальний та перевірочний набори

In [5]:

```
from sklearn.model_selection import train_test_split
```

```
moons_X_train, moons_X_test, moons_y_train, moons_y_test = train_test_split(moons_X,
moons_y, test_size=.3)
digits_X_train, digits_X_test, digits_y_train, digits_y_test =
train_test_split(digits_X, digits_y, test_size=.3)

print(f"********Load digits**********\nTraining data shape:\n {digits_X_train.shape},
{digits_y_train.shape}\n"
      f"Test data shape: \n {digits_X_test.shape}, {digits_y_test.shape}")
print(f"********Make moons**********\nTraining data shape:\n {moons_X_train.shape}
{moons_y_train.shape}\n"
      f"Test data shape: \n {moons_X_test.shape} {moons_y_test.shape}")
```

```
********Load digits**********
Training data shape:
 (1257, 64), (1257,)
Test data shape:
 (540, 64), (540,)
********Make moons**********
Training data shape:
 (840, 2) (840,)
Test data shape:
 (360, 2) (360,)
```

- побудувати різні архітектури мереж шляхом варіювання значень параметру hidden_layer_sizes; порівняти результати класифікації, отримані на основі різних архітектур

  У процесі виконання роботи було перевірено значну кількість архітектур, для наочності залишили по 5 варіантів для кожного набору даних. Результати порівнюємо шляхом підрахунку міри f1 для тестового та тренувального набору та побудови кривих втрат для кожної з моделей. `learning_rate_init=0.1, solver='sgd'` для moons та `learning_rate_init=0.01, solver='adam'` для digits обрано на основі прикладів роботи цього класифікатора на даних датасетах. Так як оптимальний параметр `max_iter` ще не обирали, він залишиться за замовчуванням доволі великим, вкажемо `early_stopping=True` щоб запобігти перенавчанню.

In [6]:

```
digits_MLPs = []
moons_MLPs = []
```

```
digits_scores = []
moons_scores = []

sizes_moons = [ (20, 10, 5, 2), (100, 50, 2), (100,), (100, 50), (4, 2, 1)]
sizes_digits = [(100,), (100, 50, 10), (100, 50), (64, 10), (64,)]

fig = plt.figure(figsize=(12, 4))
ax1 = fig.add_subplot(1, 2, 1)
ax2 = fig.add_subplot(1, 2, 2)
labels_1 = []
labels_2 = []

from sklearn.neural_network import MLPClassifier

print("---------------------Tuning hidden layers sizes--------------------")
for size_moons, size_digits in zip(sizes_moons, sizes_digits):
    digits_MLPs.append(MLPClassifier(hidden_layer_sizes=size_digits,
early_stopping=True,
                                     learning_rate_init=0.1,
solver='sgd').fit(digits_X_train, digits_y_train))
    moons_MLPs.append(MLPClassifier(hidden_layer_sizes=size_moons,
learning_rate_init=0.01,
                                    early_stopping=True,
solver='adam').fit(moons_X_train, moons_y_train))
    digits_scores.append([digits_MLPs[-1].score(digits_X_test, digits_y_test),
                          digits_MLPs[-1].score(digits_X_train, digits_y_train)])
    moons_scores.append([moons_MLPs[-1].score(moons_X_test, moons_y_test),
                         moons_MLPs[-1].score(moons_X_train, moons_y_train)])
    print(f"********Load digits**********\nhidden layers sizes:{size_digits}\n"
          f" test score: {digits_scores[-1][0]} \n"
          f" train score: {digits_scores[-1][1]}")
    print(f"********Make moons**********\nhidden layers sizes:{size_moons}\n"
          f" test score: {moons_scores[-1][0]} \n"
          f" train score: {moons_scores[-1][1]}")
    ax1.plot(moons_MLPs[-1].loss_curve_, label=f"moons layers sizes:{size_moons}")
    ax2.plot(digits_MLPs[-1].loss_curve_, label=f"digits layers sizes:{size_digits}")
    labels_1.append(f"moons layers sizes:{size_moons}")
    labels_2.append(f"digits layers sizes:{size_digits}")
ax1.legend(labels_1)
ax2.legend(labels_2)
plt.show()
```

```
---------------------Tuning hidden layers sizes--------------------
********Load digits**********
hidden layers sizes:(100,)
 test score: 0.9148148148148149
 train score: 0.9562450278440732
********Make moons**********
hidden layers sizes:(20, 10, 5, 2)
 test score: 0.5
 train score: 0.5
```

```
********Load digits**********
hidden layers sizes:(100, 50, 10)
 test score: 0.9462962962962963
 train score: 0.9976133651551312
********Make moons**********
hidden layers sizes:(100, 50, 2)
 test score: 0.5
 train score: 0.5
********Load digits**********
hidden layers sizes:(100, 50)
 test score: 0.9388888888888889
 train score: 0.9745425616547335
********Make moons**********
hidden layers sizes:(100,)
 test score: 0.85
 train score: 0.8452380952380952
********Load digits**********
hidden layers sizes:(64, 10)
 test score: 0.9314814814814815
 train score: 0.9888623707239459
********Make moons**********
hidden layers sizes:(100, 50)
 test score: 0.9
 train score: 0.9166666666666666
********Load digits**********
hidden layers sizes:(64,)
 test score: 0.95
 train score: 0.9896579156722355
********Make moons**********
hidden layers sizes:(4, 2, 1)
 test score: 0.5
 train score: 0.5
```

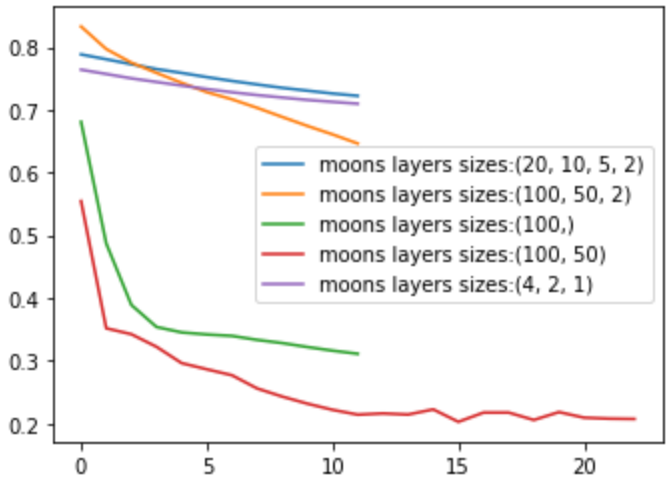

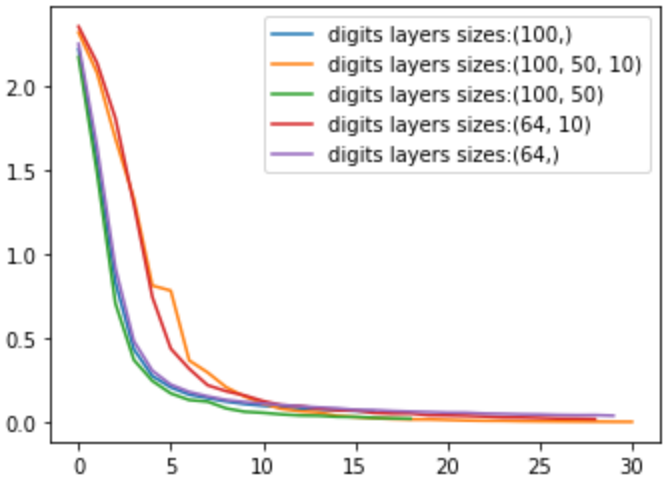

Що разу після запуску даного коду результати дещо відрізняються, проте модель для `Moons hidden_layer_sizes= (100, 50)` працює найбільш стабільно на цьому датасеті, дає найменші показники втрат як на перших так і на останніх ітераціях та найвищі показники міри f1, порівняно з іншими моделями. На `digits` декілька моделей показують майже однакову ефективність, для подальшої роботи оберемо `hidden_layer_sizes= (64,)`, з метою економії обчислювальних потужностей

- Розглянути різні значення max_iter, дослідити їх вплив на результат
- Вивести значення функції втрат на декількох перших і декількох останніх ітераціях - у кожному варіанті.

Значення функції втрат на декількох перших та декількох останніх ітераціях видно на графіку функцій втрат усіх побудованих вище та далі моделей. Якість моделей оцінюємо так само як і при зміні розміру та кількості прихованих шарів - за допомогою міри f1 для тестового та тренувального набору та побудови кривих втрат для кожної з моделей. Для усіх моделей вкажемо найкращі значення розмірів прихованих шарів, підібрані у попередньому пункті та приберемо ранню зупинку, щоб бачити як максимальна кількість ітерацій впливає на модель(у тому числі перенавчання)

In [7]:

```
iters_moons = [20, 30, 50, 100, 200]
iters_digits = [10, 20, 30, 40, 100]



fig = plt.figure(figsize=(12, 4))
ax1 = fig.add_subplot(1, 2, 1)
ax2 = fig.add_subplot(1, 2, 2)
labels_1 = []
labels_2 = []

print("----------------------Tuning max_iter ---------------------")
```

```
for iters_moons, iters_digits in zip(iters_moons, iters_digits):
    digits_MLPs.append(MLPClassifier(hidden_layer_sizes=(64,), learning_rate_init=0.1,
                                     solver='sgd',
max_iter=iters_digits).fit(digits_X_train, digits_y_train))
    moons_MLPs.append(MLPClassifier(hidden_layer_sizes=(100, 50),
learning_rate_init=0.01,
                                    solver='adam',
max_iter=iters_moons).fit(moons_X_train, moons_y_train))
    digits_scores.append([digits_MLPs[-1].score(digits_X_test, digits_y_test),
                          digits_MLPs[-1].score(digits_X_train, digits_y_train)])
    moons_scores.append([moons_MLPs[-1].score(moons_X_test, moons_y_test),
                         moons_MLPs[-1].score(moons_X_train, moons_y_train)])
    print(f"********Load digits**********\nmax_iters:{iters_digits}\n"
          f" test score: {digits_scores[-1][0]} \n"
          f" train score: {digits_scores[-1][1]}")
    print(f"********Make moons**********\nmax_iters:{iters_moons}\n"
          f" test score: {moons_scores[-1][0]} \n"
          f" train score: {moons_scores[-1][1]}")
    ax1.plot(moons_MLPs[-1].loss_curve_)
    ax2.plot(digits_MLPs[-1].loss_curve_)
    labels_1.append(f"moons max_iters:{iters_moons}")
    labels_2.append(f"digits max_iters:{iters_digits}")
ax1.legend(labels_1)
ax2.legend(labels_2)
plt.show()
```

```
----------------------Tuning max_iter --------------------
c:\users\alina\onedrive\documents\github\text
mining\venv\lib\site-packages\sklearn\neural_network\_multilayer_perceptron.py:568:
ConvergenceWarning: Stochastic Optimizer: Maximum iterations (10) reached and the
optimization hasn't converged yet.
  warnings.warn(
c:\users\alina\onedrive\documents\github\text
mining\venv\lib\site-packages\sklearn\neural_network\_multilayer_perceptron.py:568:
ConvergenceWarning: Stochastic Optimizer: Maximum iterations (20) reached and the
optimization hasn't converged yet.
  warnings.warn(
********Load digits**********
max_iters:10
 test score: 0.9388888888888889
 train score: 0.9785202863961814
********Make moons**********
max_iters:20
 test score: 0.8972222222222223
 train score: 0.9285714285714286
c:\users\alina\onedrive\documents\github\text
mining\venv\lib\site-packages\sklearn\neural_network\_multilayer_perceptron.py:568:
ConvergenceWarning: Stochastic Optimizer: Maximum iterations (20) reached and the
optimization hasn't converged yet.
  warnings.warn(
```

```
c:\users\alina\onedrive\documents\github\text
mining\venv\lib\site-packages\sklearn\neural_network\_multilayer_perceptron.py:568:
ConvergenceWarning: Stochastic Optimizer: Maximum iterations (30) reached and the
optimization hasn't converged yet.
  warnings.warn(
********Load digits**********
max_iters:20
 test score: 0.9481481481481482
 train score: 0.9904534606205251
********Make moons**********
max_iters:30
 test score: 0.9027777777777778
 train score: 0.9166666666666666
c:\users\alina\onedrive\documents\github\text
mining\venv\lib\site-packages\sklearn\neural_network\_multilayer_perceptron.py:568:
ConvergenceWarning: Stochastic Optimizer: Maximum iterations (30) reached and the
optimization hasn't converged yet.
  warnings.warn(
********Load digits**********
max_iters:30
 test score: 0.9574074074074074
 train score: 0.9960222752585521
********Make moons**********
max_iters:50
 test score: 0.8972222222222223
 train score: 0.9261904761904762
c:\users\alina\onedrive\documents\github\text
mining\venv\lib\site-packages\sklearn\neural_network\_multilayer_perceptron.py:568:
ConvergenceWarning: Stochastic Optimizer: Maximum iterations (40) reached and the
optimization hasn't converged yet.
  warnings.warn(
********Load digits**********
max_iters:40
 test score: 0.9555555555555556
 train score: 0.9984089101034208
********Make moons**********
max_iters:100
 test score: 0.8916666666666667
 train score: 0.9285714285714286
c:\users\alina\onedrive\documents\github\text
mining\venv\lib\site-packages\sklearn\neural_network\_multilayer_perceptron.py:568:
ConvergenceWarning: Stochastic Optimizer: Maximum iterations (100) reached and the
optimization hasn't converged yet.
  warnings.warn(
********Load digits**********
max_iters:100
 test score: 0.9666666666666667
 train score: 1.0
********Make moons**********
max_iters:200
```

```
test score: 0.9
train score: 0.9285714285714286
```

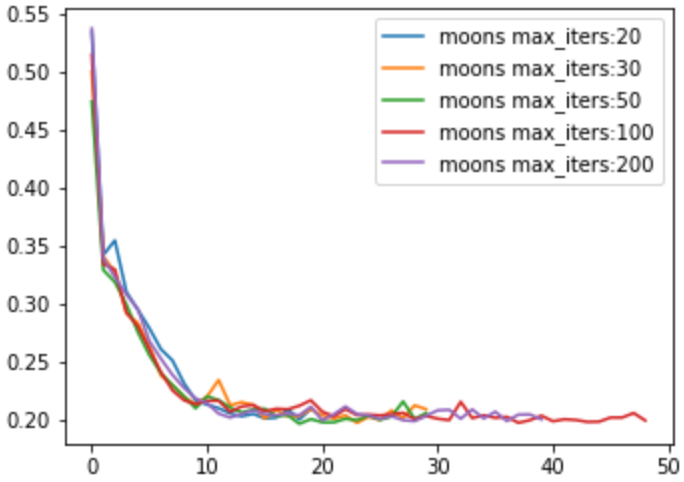

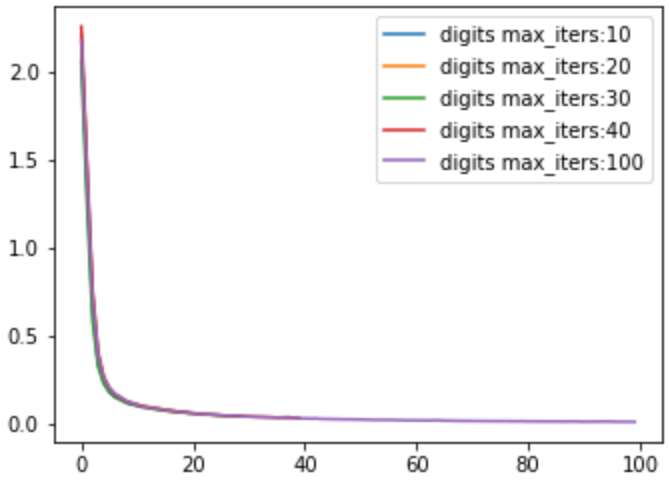

Після виконання видно, що для деяких моделей оптимізація не збіглася, що свідчить про недостатню кількість ітерацій. Можна зробити висновок що на Digits mlp працює краще і сходиться значно швидше. Після кожного перезапуску результати дещо відрізняються і тут, шляхом багаторазового виконання оберемо оптимальну максимальну кількість ітерацій як 200 і 50 - трохи більше ніж необхідно щоб перестрахуватися і додамо ранню зупинку до фінальної моделі щоб запобігти перенавчанню.

- Вивести значення середньої точності класифікації на навчальній і тестовій множинах, використовуючи score

---

In [8]:

```
import numpy as np

print(f"------------Mean Scores For All MLP models----------------\n\n"
      f"On Digits:\n"
      f" train score: {np.mean(digits_scores[:][1])}\n"
      f" test score: {np.mean(digits_scores[:][0])}\n"
      f"On Moons:\n"
      f" train score: {np.mean(moons_scores[:][1])}\n"
      f" test score: {np.mean(moons_scores[:][0])}\n")
```

```
------------Mean Scores For All MLP models----------------

On Digits:
 train score: 0.9719548307257138
```

```
 test score: 0.935529921329444
On Moons:
 train score: 0.5
 test score: 0.5
```

Тут виведмо на екран найкращі моделі з точки зору максимальної міри f1 а потім налаштуємо фінальну модель відповідно до висновків зроблених раніше.

In [9]:

```
moons_MLP_final = moons_MLPs[moons_scores.index(max(moons_scores))]
print('moons neural network with the best score:\n', moons_MLP_final, '\n\n --Setting
params after analysis--\n')
moons_MLP_final.set_params(max_iter=200, hidden_layer_sizes=(100,50),
early_stopping=True)
params = moons_MLP_final.get_params()
print('Moons:\n max_iter=',params['max_iter'], '\n hidden_layer_sizes=',
params['hidden_layer_sizes'] )

digits_MLP_final = digits_MLPs[digits_scores.index(max(digits_scores))]
print('digits neural network with the best score:\n', digits_MLP_final, '\n\n --Setting
params after analysis--\n')
digits_MLP_final.set_params(max_iter=50, hidden_layer_sizes=(64,), early_stopping=True)
params = digits_MLP_final.get_params()
print('Digits:\n \n max_iter=', params['max_iter'], '\n hidden_layer_sizes=',
params['hidden_layer_sizes'] )
```

```
moons neural network with the best score:
 MLPClassifier(activation='relu', alpha=0.0001, batch_size='auto', beta_1=0.9,
              beta_2=0.999, early_stopping=False, epsilon=1e-08,
              hidden_layer_sizes=(100, 50), learning_rate='constant',
              learning_rate_init=0.01, max_fun=15000, max_iter=30, momentum=0.9,
              n_iter_no_change=10, nesterovs_momentum=True, power_t=0.5,
              random_state=None, shuffle=True, solver='adam', tol=0.0001,
              validation_fraction=0.1, verbose=False, warm_start=False)

 --Setting params after analysis--

Moons:
 max_iter= 200
 hidden_layer_sizes= (100, 50)
digits neural network with the best score:
 MLPClassifier(activation='relu', alpha=0.0001, batch_size='auto', beta_1=0.9,
              beta_2=0.999, early_stopping=False, epsilon=1e-08,
              hidden_layer_sizes=(64,), learning_rate='constant',
              learning_rate_init=0.1, max_fun=15000, max_iter=100, momentum=0.9,
              n_iter_no_change=10, nesterovs_momentum=True, power_t=0.5,
              random_state=None, shuffle=True, solver='sgd', tol=0.0001,
              validation_fraction=0.1, verbose=False, warm_start=False)
```

```
 --Setting params after analysis--

Digits:

 max_iter= 50
 hidden_layer_sizes= (64,)
```

3. Виконати прогнози на основі моделей нейронних мереж.

In [10]:

```
digits_MLP_predicted = digits_MLP_final.predict(digits_X_test)
digits_MLP_probas = digits_MLP_final.predict_proba(digits_X_test)

moons_MLP_predicted = moons_MLP_final.predict(moons_X_test)
moons_MLP_probas = moons_MLP_final.predict_proba(moons_X_test)
```

4. Зробити висновки про якість роботи моделей нейронних мереж на досліджених даних. В задачах класифікації для кожної навчальної вибірки вибрати найкращу модель за критеріями якості:

- матриця неточностей (confusion matrix),
- точність (precision),
- повнота (recall),
- міра F1 (F1 score),
- ROC-крива, показник AUC.

Тут використаємо функцію з 2-ї лабораторної, дещо її підлаштувавши

In [11]:

```
def model_quality(clf_name, data_name, y_test, predicted, predicted_probas):

    fig = plt.figure(figsize=(18,4))
    ax1 = fig.add_subplot(1, 3, 1)
    ax2 = fig.add_subplot(1, 3, 2)
    ax3 = fig.add_subplot(1, 3, 3)

    skplt.metrics.plot_confusion_matrix(y_test, predicted, ax=ax1,
                                        title=f'Confusion Matrix for {clf_name}
{data_name}')
    print(f"classiffication report for {clf_name} {data_name}"
          f"\n------------------------------\n"
          f"{metrics.classification_report(y_test, predicted)}")
    skplt.metrics.plot_precision_recall(y_test, predicted_probas, ax=ax2,
                                        title=f'Precision-Recall curves for {clf_name}
{data_name}')
    skplt.metrics.plot_roc(y_test, predicted_probas, ax=ax3,
```

```
                          title=f'ROC curves for {clf_name} {data_name}')
    plt.show()
```

In [12]:

```
for clf_name, data_name, clf, X, y, \
    test, predicted, probas in [['MLP for', 'Moons',
                                 moons_MLP_final, moons_X, moons_y, moons_y_test,
                                 moons_MLP_predicted, moons_MLP_probas],
                                ['MLP for', 'Digits',
                                 digits_MLP_final, digits_X, digits_y, digits_y_test,
                                 digits_MLP_predicted, digits_MLP_probas],
                                ]:
    model_quality(clf_name, data_name, test, predicted, probas)
```

```
classiffication report for MLP for Moons
--------------------------------
              precision    recall  f1-score   support

           0       0.91      0.89      0.90       180
           1       0.90      0.91      0.90       180

    accuracy                           0.90       360
   macro avg       0.90      0.90      0.90       360
weighted avg       0.90      0.90      0.90       360
```

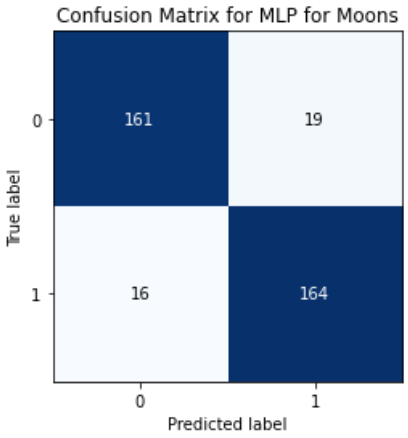

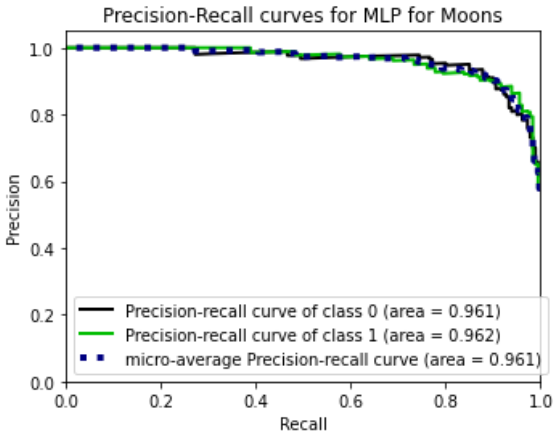

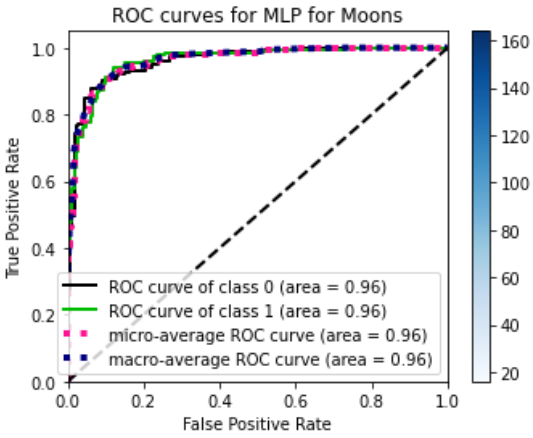


```
classiffication report for MLP for Digits
--------------------------------
              precision    recall  f1-score   support

           0       1.00      1.00      1.00        45
           1       0.86      0.96      0.91        57
           2       0.97      0.98      0.97        58
           3       1.00      1.00      1.00        59
           4       1.00      0.98      0.99        55
           5       0.96      0.98      0.97        55
           6       1.00      0.96      0.98        52
           7       0.96      0.98      0.97        47
```

```
           8       0.96      0.87      0.91        52
           9       0.98      0.95      0.97        60

    accuracy                           0.97       540
   macro avg       0.97      0.97      0.97       540
weighted avg       0.97      0.97      0.97       540
```

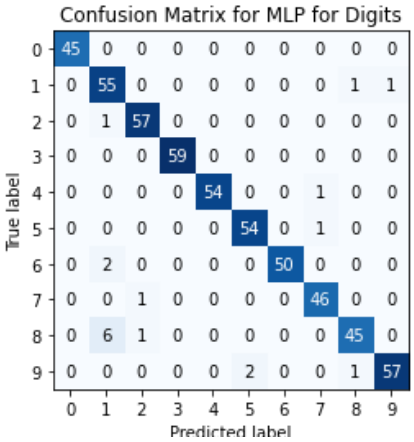

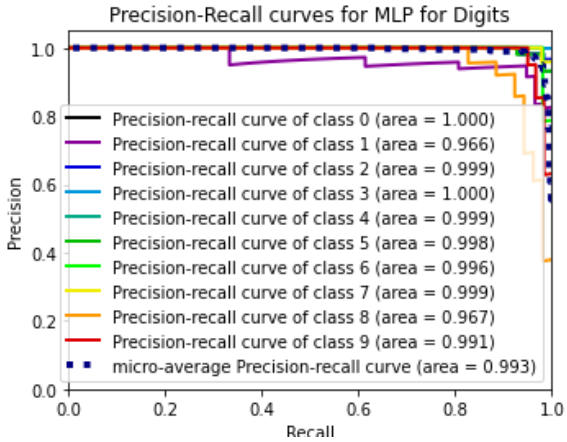

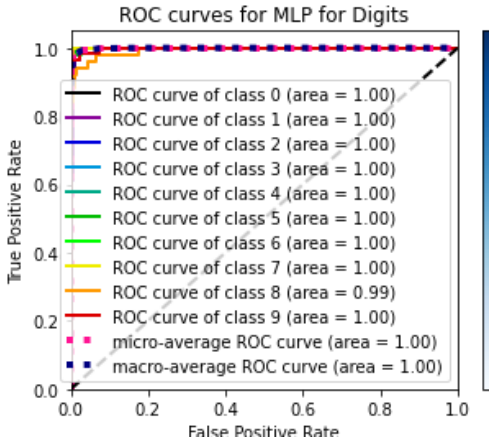

Очевидно моделі багатошарового перцептрона працюють краще ніж моделі наївної байєсівської класифікації. За допомогою правильного підбору гіперпараметрів вдалося досягти доволі високих показників.

5. Побудувати ансамблі моделей, використовуючи наступні методи згідно з варіантом:

StackingClassifier. Розглянути різні значення параметрів final estimator, stack_method.

Спочатку напишемо функцію підрахунку f1 та auc для заданої моделі на заданих тренувальних та тестових даних

In [13]:

```
from sklearn.ensemble import StackingClassifier
from sklearn.naive_bayes import GaussianNB, MultinomialNB
from sklearn.preprocessing import OneHotEncoder

def f1_auc_calc(ens_metrics, X_train, X_test, y_test, clf, data_name):

    ens_metrics[data_name]['f1'].append(clf.score(X_test, y_test))

    if X_train.shape[0] > 2:
```

```
        encoded_test = OneHotEncoder(sparse=False).fit_transform(y_test.reshape(-1, 1))
        encoded_preds =
OneHotEncoder(sparse=False).fit_transform(clf.predict(X_test).reshape(-1, 1))
        ens_metrics[data_name]['auc'].append(metrics.roc_auc_score(encoded_test,
encoded_preds))
    else:
        ens_metrics[data_name]['auc'].append(metrics.roc_auc_score(y_test,
clf.predict(X_test)))
    return ens_metrics
```

Наступний етап - напишемо функцію створення ансамблів з заданими гіперпараметрами `estimators, final_estimator, stack_method` Які у подальшому будемо змінювати або задавати згідно з варіантом. У цій функції викличемо попередню функцію щоб вести облік цікавих нам метрик новостворених ансамблів.

In [14]:

```
def make_ensembles(stacking_methods, final_estimators, estimators, ens_metrics,
                   data_name, X_train, y_train, X_test, y_test):


    for staking_method in stacking_methods:
        for final_estimator in final_estimators[data_name]:
            stacking_clf = StackingClassifier(estimators=estimators[data_name],
                                              final_estimator=final_estimator,
                                              stack_method=staking_method)
            stacking_clf.fit(X_train, y_train)
            ensembles[data_name].append(stacking_clf)
            ens_metrics = f1_auc_calc(ens_metrics, X_train, X_test, y_test,
stacking_clf, data_name)
    return  ens_metrics
```

6. Побудувати ансамбль StackingClassifier на основі найпростіших моделей:

• В якості estimators використати одну/ декілька найпростіших моделей заданих за варіантом:

Дослідити ансамблі, які включають моделі нейронних мереж та моделі наївної байесівської класифікації, отримані в роботі №2.

Порівняти значення мір F1_score та AUC для ансамблів та окремих моделей, які утворюють ансамбль
(estimators). Порівняти кілька ансамблів, які утворені на основі одних estimates і відрізняються значеннями параметрів.

Порівнювати значення мір F1_score та AUC для ансамблів та окремих моделей, які утворюють ансамбль будемо для фінального ансамблю, підібравши найбільш ефективний.
Задаємо початкові дані, та використовуємо функції, написані раніше.

In [15]:

```
stacking_methods = ['auto', 'predict_proba', 'predict']
final_estimators = {'moons':[None, GaussianNB(), moons_MLP_final ],
                    'digits':[None, MultinomialNB(), GaussianNB(), digits_MLP_final]}
estimators = {'moons':[('gnb', GaussianNB()),('mlp', moons_MLP_final)],
              'digits': [('mnb', MultinomialNB()), ('mlp', digits_MLP_final)]}

ensembles = {'moons':[], 'digits':[]}
ens_metric = {'moons':{'f1': [], 'auc': []}, 'digits':{'f1': [], 'auc': []}}

ens_metric = make_ensembles(stacking_methods, final_estimators, estimators, ens_metric,
               'moons', moons_X_train, moons_y_train, moons_X_test, moons_y_test)
ens_metric = make_ensembles(stacking_methods, final_estimators, estimators, ens_metric,
               'digits', digits_X_train, digits_y_train, digits_X_test, digits_y_test)
```

```
c:\users\alina\onedrive\documents\github\text
mining\venv\lib\site-packages\sklearn\linear_model\_logistic.py:938:
ConvergenceWarning: lbfgs failed to converge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
    https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
  n_iter_i = _check_optimize_result(
```

• Побудувати графіки залежності значень помилок класифікації accuracy_score або zero_one_loss від значення n_estimators для досліджених ансамблів та окремих моделей на одній координатній вісі.

• В задачах класифікації побудувати графіки залежності значень мі-

ри F1_score від значення n_estimators для досліджених ансамблів та окремих моделей на одній координатній вісі. Аналогічні графіки побудувати для AUC. Графіки для окремих моделей, очевидно, будуть горизонтальними прямими.

Відсутній параметр n_estimators(можна порахувати, але він не змінюється оскільки estimators одні й ті ж). Тому побудова графіків не має сенсу, будемо вести облік значень F1_score та AUC і представимо їх для усіх побудованих ансамблів та моделей з яких вони складаються замість побудови графіків.

In [16]:

```
for data_name in ['moons', 'digits']:
    index = []
    for ens in ensembles[data_name]:
        index.append(f"stack_method={ens.get_params()['stack_method']},"
                     f"final_estimator={ens.get_params()['final_estimator']}")
    data_metrics = DataFrame(data=ens_metric[data_name], index=index)
    print(f"------Stacking CLFs for {data_name}----------\n"
          f"{data_metrics}")
```

```
------Stacking CLFs for moons----------
                                                      f1       auc
stack_method=auto,final_estimator=None              0.894444  0.894444
stack_method=auto,final_estimator=GaussianNB(pr...  0.900000  0.900000
stack_method=auto,final_estimator=MLPClassifier...  0.894444  0.894444
stack_method=predict_proba,final_estimator=None     0.897222  0.897222
stack_method=predict_proba,final_estimator=Gaus...  0.908333  0.908333
stack_method=predict_proba,final_estimator=MLPC...  0.894444  0.894444
stack_method=predict,final_estimator=None           0.875000  0.875000
stack_method=predict,final_estimator=GaussianNB...  0.894444  0.894444
stack_method=predict,final_estimator=MLPClassif...  0.894444  0.894444
------Stacking CLFs for digits----------
                                                      f1       auc
stack_method=auto,final_estimator=None              0.946296  0.970562
stack_method=auto,final_estimator=MultinomialNB...  0.931481  0.962665
stack_method=auto,final_estimator=GaussianNB(pr...  0.931481  0.962487
stack_method=auto,final_estimator=MLPClassifier...  0.940741  0.967650
stack_method=predict_proba,final_estimator=None     0.927778  0.960790
stack_method=predict_proba,final_estimator=Mult...  0.925926  0.959603
stack_method=predict_proba,final_estimator=Gaus...  0.911111  0.951445
stack_method=predict_proba,final_estimator=MLPC...  0.916667  0.955327
stack_method=predict,final_estimator=None           0.922222  0.957054
stack_method=predict,final_estimator=Multinomia...  0.170370  0.749113
stack_method=predict,final_estimator=GaussianNB...  0.838889  0.909705
stack_method=predict,final_estimator=MLPClassif...  0.650000  0.866343
```

Збережемо індекс ансамблю з максимальною мірою f1 та його метрики. З кожним новим запуском результати дещо відрізняються, визначити найкращий ансамбль аналітично не вдалося, робимо висновок що декілька з них працюють на рівних, тому вважаємо за найкращий той що виявився найкращим цього разу.

In [17]:

```
index_of_maxf1_moons = ens_metric['moons']['f1'].index(max(ens_metric['moons']['f1']))
final_scores_moons ={'f1':ens_metric['moons']['f1'][index_of_maxf1_moons],
                     'auc':ens_metric['moons']['auc'][index_of_maxf1_moons]}
moons_final_ensemble = ensembles['moons'][index_of_maxf1_moons]
print(f"moons_final_ensemble = {moons_final_ensemble}\n{final_scores_moons}")
moons_final_ensemble = StackingClassifier(cv=None,
                   estimators=[('gnb',
                                GaussianNB(priors=None, var_smoothing=1e-09)),
                               ('mlp',
                                MLPClassifier(activation='relu', alpha=0.0001,
                                              batch_size='auto', beta_1=0.9,
                                              beta_2=0.999, early_stopping=True,
                                              epsilon=1e-08,
                                              hidden_layer_sizes=(100, 50),
                                              learning_rate='constant',
                                              learning_rate_init=0.01,
                                              max_fun=15000, max_iter=200,
                                              momentum=0.9, n_iter_no_change=10,
                                              nesterovs_momentum=True,
                                              power_t=0.5, random_state=None,
                                              shuffle=True, solver='adam',
                                              tol=0.0001,
                                              validation_fraction=0.1,
                                              verbose=False,
                                              warm_start=False))],
                   final_estimator=GaussianNB(priors=None, var_smoothing=1e-09),
                   n_jobs=None, passthrough=False, stack_method='predict_proba',
                   verbose=0)
{'f1': 0.9083333333333333, 'auc': 0.9083333333333332}
```

In [18]:

```
index_of_maxf1_digits =
ens_metric['digits']['f1'].index(max(ens_metric['digits']['f1']))
final_scores_digits = {'f1':ens_metric['digits']['f1'][index_of_maxf1_digits],
                       'auc':ens_metric['digits']['auc'][index_of_maxf1_digits]}
digits_final_ensemble = ensembles['digits'][index_of_maxf1_digits]
print(f"digits_final_ensemble = {digits_final_ensemble}\n{final_scores_digits}")
digits_final_ensemble = StackingClassifier(cv=None,
                   estimators=[('mnb',
                                MultinomialNB(alpha=1.0, class_prior=None,
                                              fit_prior=True)),
```

```
                                ('mlp',
                                 MLPClassifier(activation='relu', alpha=0.0001,
                                               batch_size='auto', beta_1=0.9,
                                               beta_2=0.999, early_stopping=True,
                                               epsilon=1e-08,
                                               hidden_layer_sizes=(64,),
                                               learning_rate='constant',
                                               learning_rate_init=0.1,
                                               max_fun=15000, max_iter=50,
                                               momentum=0.9, n_iter_no_change=10,
                                               nesterovs_momentum=True,
                                               power_t=0.5, random_state=None,
                                               shuffle=True, solver='sgd',
                                               tol=0.0001,
                                               validation_fraction=0.1,
                                               verbose=False,
                                               warm_start=False))],
                    final_estimator=None, n_jobs=None, passthrough=False,
                    stack_method='auto', verbose=0)
{'f1': 0.9462962962962963, 'auc': 0.9705623863923327}
```

• В задачах класифікації відобразити границі рішень decision boundaries на основі estimators та на основі досліджених ансамблів.

Для digits не має сенсу, покажемо для moons

In [19]:

```
i = 1
```

```
clfs = {'moons': moons_final_ensemble.estimators_,
        'digits': digits_final_ensemble.estimators_}

clfs['moons'].append(moons_final_ensemble)
clfs['digits'].append(digits_final_ensemble)

for clf in zip (['gnb', 'mlp', 'stack'], clfs['moons']):
    x_min, x_max = moons_X[:, 0].min() - 0.5, moons_X[:, 0].max() + 0.5
    y_min, y_max = moons_X[:, 1].min() - 0.5, moons_X[:, 1].max() + 0.5
    xx, yy = np.meshgrid(np.arange(x_min, x_max, 0.2),
                         np.arange(y_min, y_max, 0.2))

    df = DataFrame(dict(x=moons_X[:, 0], y=moons_X[:, 1], label=moons_y))
    fig = plt.figure()
    ax = fig.add_subplot()
    grouped = df.groupby('label')
    for key, group in grouped:
        group.plot(ax=ax, kind='scatter', x='x', y='y', label=key, color=colors[key])
```

```
        Z = clf[1].predict_proba(np.c_[xx.ravel(), yy.ravel()])[:, 1]
        Z = Z.reshape(xx.shape)
        ax.contourf(xx, yy, Z, alpha=0.2, cmap=plt.cm.PuOr)
        ax.set_title(f"decision boundary for {clf[0]}")
    i += 1
plt.show()
```

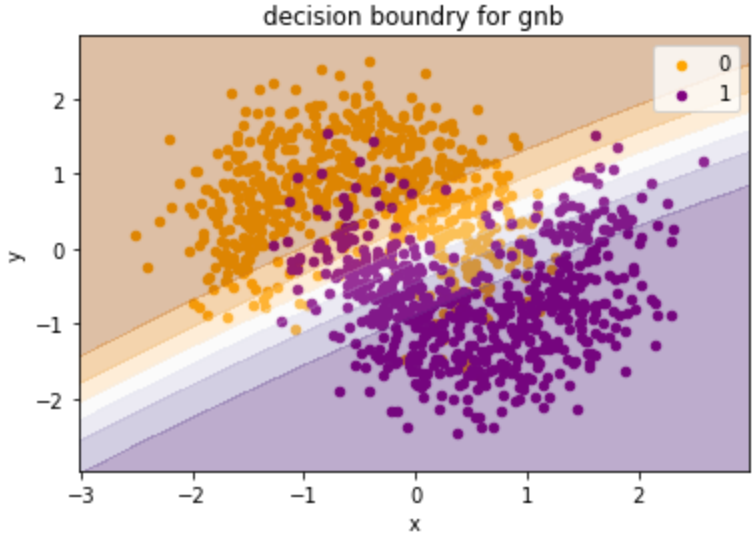

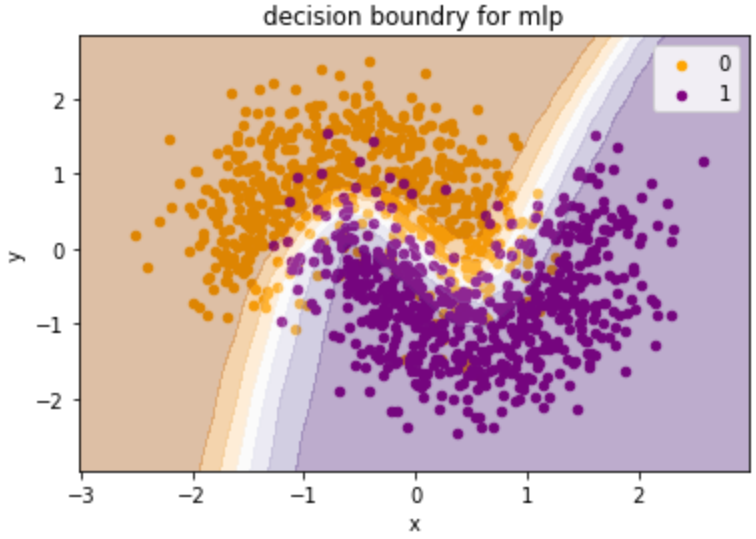

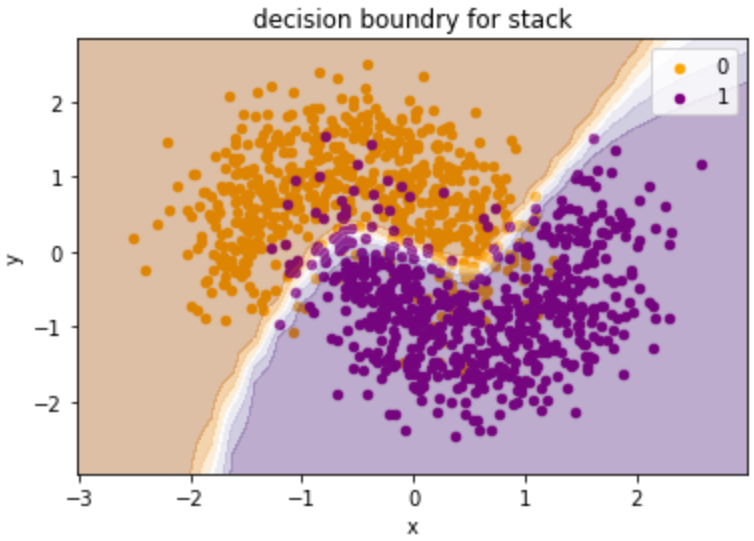

7. Побудувати ансамблі на основі найкращої моделі / моделей нейронних мереж, знайдених на попередніх етапах даної роботи, та найкращої моделі / моделей, знайдених у роботі No2.
Порівняти результати класифікації, значення мір F1_score та AUC для ансамблів та окремих моделей, які утворюють ці ансамблі.

In [20]:

```
print('-----------Best Classifiers Comparison----------')

clfs_metrics = {'moons':{'f1': [], 'auc': []}, 'digits':{'f1': [], 'auc': []}}

for data_name, X_train, X_test, y_test in zip(['moons', 'digits'],
                                              [moons_X_train, digits_X_train],
                                              [moons_X_test, digits_X_test],
                                              [moons_y_test, digits_y_test]):
    for clf in clfs[data_name]:
        clfs_metrics = f1_auc_calc(clfs_metrics, X_train, X_test,
                                   y_test, clf, data_name)

    index =[]
    for estimator in estimators[data_name]:
        index.append(estimator[0])
    index.append('stack')
    df = DataFrame(data=clfs_metrics[data_name], index=index)
    print(f"\n{data_name}\n{df}")
```

```
-----------Best Classifiers Comparison----------

moons
             f1       auc
gnb    0.866667  0.866667
mlp    0.905556  0.905556
```

```
stack  0.908333  0.908333

digits
              f1       auc
mnb    0.888889  0.940240
mlp    0.951852  0.973462
stack  0.946296  0.970562
```

Moons

Вдалося значно покращити результат класифікації після переходу від наївного байєса до нейронної мережі. Проте після правильного налаштування мережі вона вже надає майже максимально можливу для цього набору даних якість класифікації, тому побудова ансамблю не має особливого сенсу.

Digits

Аналогічно, вдалося значно покращити результат класифікації після переходу від наївного байєса до нейронної мережі. Нейронна мережа працює ефективніше на цьому датасеті. Швидше сходиться, потребує простішої архітектури прихованих шарів. Перехід від мережі до ансамблю до разючого покращення не призвів, проте результат коливався при кожному запуску програми, і для більшості все ж таки можна було спостерігати певне покращення.